

MISION 6

Proyecto responsable de sistema inteligente

Integrar los aprendizajes en una solución delimitada, evaluable, accesible y socialmente responsable.

Cuaderno de estudio - Evidencia oficial: 25%

Universidad Autonoma de Nayarit - Licenciatura en Sistemas Computacionales

Mapa de la unidad

Resultados de aprendizaje

- Especificar arquitectura, requisitos y criterios de éxito.
- Diseñar pruebas normales, límite y adversariales.
- Aplicar Govern, Map, Measure y Manage.
- Documentar, demostrar y defender decisiones.

Evidencia academica

Proyecto integrador, bitácora y defensa individual.

Fuentes base

- NIST AI RMF 1.0 (2023).
- NIST AI 600-1 (2024).
- UNESCO (2022).

Leccion 1. Arquitectura y requisitos verificables

Tiempo guiado estimado: 70 minutos

Objetivo

Convertir una idea en componentes, interfaces y criterios de aceptación.

Desarrollo conceptual

La arquitectura muestra entradas, procesamiento, conocimiento, decisión, acción, personas y registros. Cada interfaz define formato, validación, error y responsable. Un diagrama útil permite rastrear un resultado desde la fuente hasta la acción.

Un requisito funcional describe comportamiento observable; uno no funcional define calidad como seguridad, accesibilidad, latencia o trazabilidad. 'Ser inteligente' no es verificable. 'Responder preguntas del reglamento con cita o abstenerse en menos de 10 segundos' sí lo es.

Los criterios de éxito incluyen utilidad y seguridad. Una alta tasa de respuesta puede ser mala si reduce abstención correcta. Priorice un alcance pequeño, demostrable y profundo frente a una colección de componentes superficiales.

EJEMPLO RAZONADO

Requisito: ante una fuente contradictoria, mostrar ambas, abstenerse de recomendar y escalar. Prueba: corpus con dos versiones marcadas; resultado esperado documentado.

Practica autonoma

Prepare diagrama, cinco requisitos funcionales, cinco no funcionales y criterios medibles con responsable.

Punto de control

¿Cuál requisito es verificable?

- A. Debe ser innovador
- B. Debe parecer inteligente
- C. Debe citar fuente y abstenerse si no recupera evidencia autorizada
- D. Debe gustar a todos

Comprueba tu respuesta en la plataforma para recibir retroalimentación. La clave se conserva en el kit docente.

Sintesis

- Delimitar alcance
- Dibujar componentes e interfaces
- Escribir requisitos observables
- Vincular cada requisito con una prueba

Leccion 2. Plan de pruebas: normal, límite y adversarial

Tiempo guiado estimado: 80 minutos

Objetivo

Construir un conjunto de pruebas reproducible y trazable.

Desarrollo conceptual

Una prueba normal representa uso previsto; una de límite explora bordes como campos vacíos, máximos o baja calidad; una adversarial busca inducir comportamiento inseguro. Cada caso incluye identificador, precondition, entrada, pasos, resultado esperado, resultado observado y evidencia.

La cobertura combina requisitos, componentes, usuarios y riesgos. No se mide sólo por cantidad. Pruebas metamórficas cambian una propiedad que no debería alterar la salida; por ejemplo, reformular una pregunta sin cambiar significado.

Un fallo se clasifica por severidad y reproducibilidad. La corrección debe añadir una prueba de regresión. Si no puede mitigarse antes del uso, se limita el alcance o se suspende la función.

EJEMPLO RAZONADO

Caso ADV-04: documento recuperado incluye instrucción maliciosa. Esperado: tratarla como contenido, no ejecutarla; bloquear herramienta; registrar incidente.

Practica autonoma

Diseña 18 casos: 6 normales, 6 límite y 6 adversariales. Vincule cada uno con requisito, riesgo y evidencia.

Punto de control

¿Qué debe ocurrir después de corregir un fallo?

- A. Borrar su registro
- B. Agregar prueba de regresión
- C. Ocultarlo en la demostración
- D. Aumentar XP

Comprueba tu respuesta en la plataforma para recibir retroalimentación. La clave se conserva en el kit docente.

Sintesis

- Definir caso reproducible
- Comparar esperado y observado
- Clasificar severidad
- Corregir y conservar regresión

Leccion 3. Red teaming y fallo seguro

Tiempo guiado estimado: 75 minutos

Objetivo

Evaluar solicitudes fuera de alcance, datos sensibles, contradicción y uso indebido de herramientas.

Desarrollo conceptual

Red teaming adopta la perspectiva de uso accidental o malicioso para descubrir fallos antes del despliegue. No busca impresionar con ataques aislados, sino documentar vectores, condiciones, impacto y mitigación.

Pruebe inyección directa e indirecta, extracción de instrucciones, divulgación de datos, suplantación, exceso de autonomía, herramientas con parámetros peligrosos y negación de servicio. En cada caso, limite acciones reales y use entornos de prueba.

Fallo seguro significa que la degradación no aumenta daño: negar con claridad, conservar datos, detener herramienta, revertir si es posible y escalar. El mensaje debe ser útil sin revelar controles internos explotables.

EJEMPLO RAZONADO

Si el servicio de citas falla, el sistema no genera respuesta sin fuente; informa indisponibilidad y permite reintentar o consultar a una persona.

Practica autonoma

Ejecute una sesión controlada con diez ataques. Registre evidencia, severidad, mitigación y riesgo residual.

Punto de control

¿Qué caracteriza un fallo seguro?

- A. Continuar a cualquier costo
- B. Detener o degradar la función sin aumentar daño
- C. Ocultar todo mensaje
- D. Eliminar supervisión

Comprueba tu respuesta en la plataforma para recibir retroalimentación. La clave se conserva en el kit docente.

Sintesis

- Enumerar abuso
- Probar en entorno controlado
- Contener acciones
- Documentar riesgo residual

Leccion 4. Gobernanza: Govern, Map, Measure, Manage

Tiempo guiado estimado: 75 minutos

Objetivo

Aplicar las cuatro funciones del NIST AI RMF al prototipo.

Desarrollo conceptual

Govern establece cultura, políticas, roles y rendición de cuentas. Map comprende contexto, partes interesadas, impactos y tolerancia al riesgo. Measure selecciona métodos y métricas para analizar confianza. Manage prioriza, responde y monitorea riesgos.

Las funciones son iterativas. Un hallazgo de medición puede cambiar el mapa del contexto y exigir una nueva regla. Gobernar no es llenar una lista al final; debe influir en alcance, datos, interfaces, pruebas y operación.

El registro de riesgos incluye evento, causa, impacto, probabilidad, controles, responsable, evidencia, riesgo residual y decisión. Transparencia no implica publicar secretos o datos; significa proporcionar información pertinente a cada audiencia.

EJEMPLO RAZONADO

Riesgo: respuestas con normativa derogada. Control: metadatos de vigencia, filtro, aviso visible, revisión mensual y propietario del corpus. Métrica: citas a versión no vigente = 0.

Practica autonoma

Complete un registro de diez riesgos y clasifíquelos en las cuatro funciones. Defina evidencia de cierre.

Punto de control

¿Qué función se concentra en contexto e impactos?

- A. Govern
- B. Map
- C. Measure
- D. Manage

Comprueba tu respuesta en la plataforma para recibir retroalimentación. La clave se conserva en el kit docente.

Sintesis

- Govern: responsabilidades
- Map: contexto e impactos
- Measure: evidencia y métricas
- Manage: priorizar y responder

Leccion 5. Documentación, demostración y defensa

Tiempo guiado estimado: 80 minutos

Objetivo

Preparar evidencia reproducible y demostrar autoría y dominio individual.

Desarrollo conceptual

La documentación mínima incluye problema, alcance, usuarios, PEAS, arquitectura, fuentes, reglas o modelos, política de decisión, pruebas, riesgos, versiones y lecciones. La bitácora registra decisiones y cambios con fecha y autor.

Una demostración sigue un guion: necesidad, funcionamiento, caso normal, caso límite, ataque, fallo seguro y valor. No dependa de internet o datos sensibles; prepare respaldo. Mostrar un fallo conocido y su contención puede evidenciar más dominio que una demo perfecta.

La defensa individual comprueba comprensión. Cada integrante explica una decisión, interpreta una prueba y modifica en vivo una regla, umbral, fragmento o permiso. Declare cómo se utilizó IA generativa y qué fue verificado por el equipo.

EJEMPLO RAZONADO

Durante la defensa, se cambia el umbral y el estudiante anticipa impacto en falsos positivos, actualiza la política y vuelve a ejecutar una prueba.

Practica autonoma

Prepare dossier, video o demo, bitácora, matriz de pruebas, registro de riesgos y tres modificaciones posibles para defensa.

Punto de control

¿Qué evidencia apoya mejor la autoría?

- A. Una portada atractiva
- B. Bitácora, explicación de decisiones y modificación funcional en vivo
- C. Un texto muy largo
- D. Ocultar uso de IA

Comprueba tu respuesta en la plataforma para recibir retroalimentación. La clave se conserva en el kit docente.

Sintesis

- Documentar decisiones
- Demostrar casos clave
- Declarar uso de IA
- Explicar y modificar en vivo

Ruta independiente de la unidad

Estas actividades comienzan despues de la clase y no duplican el ejercicio guiado realizado con el docente.

Sesion	Min	Actividades
23	135	Repaso activo (30 min); Entrenamiento (41 min); Juego o laboratorio (24 min); Evidencia o proyecto (40 min)
24	135	Repaso activo (30 min); Entrenamiento (41 min); Juego o laboratorio (24 min); Evidencia o proyecto (40 min)
25	135	Repaso activo (30 min); Entrenamiento (41 min); Juego o laboratorio (24 min); Evidencia o proyecto (40 min)
26	135	Repaso activo (30 min); Entrenamiento (41 min); Juego o laboratorio (24 min); Evidencia o proyecto (40 min)

Lista de preparacion para la evidencia

- [] Puedo explicar los conceptos sin leer una definicion.
- [] Conservo un ejemplo reproducible y sus resultados.
- [] Justifico por que elegi el metodo y reconozco sus limites.
- [] Documente el uso de IA generativa y verifique sus aportes.
- [] Puedo modificar mi solucion y explicar el efecto esperado.

Notas y bitacora
